Unidad II: Preparaci´on de la informaci´on

Docente: Guillermo Pinto

Facultad de Ingeniería

Minería de Datos
2025

Table of Contents

1. Causalidad vs. Correlación
2. Coeficientes de correlación
3. Modelo de regresión lineal simple
4. Modelo de regresión lineal múltiple
   - Análisis de Varianza
   - Coeficiente de determinación
   - Inferencia de los coeficientes
5. Conclusiones
6. Referencias

Table of Contents

1. Causalidad vs. Correlación
2. Coeficientes de correlación
3. Modelo de regresión lineal simple
4. Modelo de regresión lineal múltiple
   - Análisis de Varianza
   - Coeficiente de determinación
   - Inferencia de los coeficientes
5. Conclusiones
6. Referencias

Causalidad vs. Correlación

Los países con mayor consumo de chocolate tienen más premios Nobel, por lo que se recomienda su consumo para mejorar la inteligencia [Maurage *et al.*, 2013].

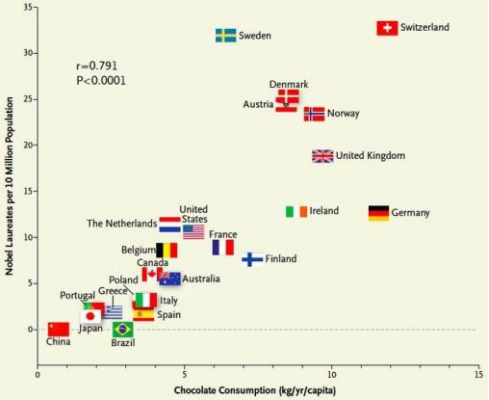

"el consumo de chocolate mejora la función cognitiva" (New England Journal, 2012)

Causalidad vs. Correlación

Algunos ejemplos:

- "va a temblar porque está haciendo mucho calor"
- "Los felizmente casados sobreviven más que los solteros tras un 'by-pass'"
- "La sobreinformación es la causante del síndrome de fatiga informativa"
- "Ver la televisión acorta la vida hasta en cinco años"

La correlación no justifica en absoluto la existencia de una relación de causa-efecto; y la ausencia de correlación tampoco implica que no exista relación causa-efecto.

Causalidad vs. Correlación

Correlación

- Es una comparación o descripción de la asociación entre variables.

Causalidad vs. Correlación

Correlación

- Es una comparación o descripción de la asociación entre variables.
- Los cambios de alguna variable Y pueden ser explicados por los cambios de la otra X.

Causalidad vs. Correlación

Correlación

- Es una comparación o descripción de la asociación entre variables.
- Los cambios de alguna variable Y pueden ser explicados por los cambios de la otra X.
- Medida bivariada que mide la magnitud de la asociación entre dos variables y la dirección de dicha relación (-1 a 1), mientras que la regresión lineal genera un modelo.

Causalidad vs. Correlación

Universidad Andrés Bello

Correlación

- Es una comparación o descripción de la asociación entre variables.
- Los cambios de alguna variable Y pueden ser explicados por los cambios de la otra X.
- Medida bivariada que mide la magnitud de la asociación entre dos variables y la dirección de dicha relación (-1 a 1), mientras que la regresión lineal genera un modelo.
- La visualización más común de datos bivariados es el diagrama de dispersión (*Scatterplot*), donde la coordenada x corresponde a el valor de una variable y se coordinan con el valor de la otra variable.

Causalidad vs. Correlación

Correlación

Las variables están correlacionadas positivamente, negativamente correlacionados o no correlacionados.

+ los valores de más grandes de una variable se asocian con los valores de más grandes de la otra.

Causalidad vs. Correlación

Correlación

Las variables están correlacionadas positivamente, negativamente correlacionados o no correlacionados.

+ los valores de más grandes de una variable se asocian con los valores de más grandes de la otra.
- el aumento en una variable resulta en una disminución en la otra variable.

Causalidad vs. Correlación

Correlación

Las variables están correlacionadas positivamente, negativamente correlacionados o no correlacionados.

+ los valores de más grandes de una variable se asocian con los valores de más grandes de la otra.
- el aumento en una variable resulta en una disminución en la otra variable.
N Un aumento en una variable no tiene ningún efecto aparente sobre la otra.

Causalidad vs. Correlación

Examples (1)

En un estudio geoquímico de suelo realizado por Servicio Geológico de Estados Unidos (USGS) [Smith *et al.*, 2010] en el estado de Colorado, se recolectaron muestras en más de 500 sitios, para detectar cambios en la composición del suelo que podr´ıan resultar de procesos naturales o actividades antropogénicas. A continuación se muestra el porcentaje de aluminio (Al) y hierro (Fe) encontrados en 30 sitios.

Al	4.65 6.36 6.33 3.60 6.89 6.29 5.92 5.83 4.01 7.78 3.17 6.91 6.48 5.97 5.11 7.35 4.89 5.42 6.32 5.18 7.64 5.22 4.28 6.04 5.60 5.97 6.48 4.08 6.15 3.87
Fe	1.20 2.19 1.52 0.63 2.88 2.22 2.48 1.60 1.02 2.08 1.30 4.05 2.56 2.58 2.23 3.94 1.65 1.83 3.17 2.35 2.53 2.15 1.20 1.78 2.61 2.77 3.71 1.96 2.17 1.75

Causalidad vs. Correlación

Examples (1)

Diagrama de dispersión (*Scatterplot*)

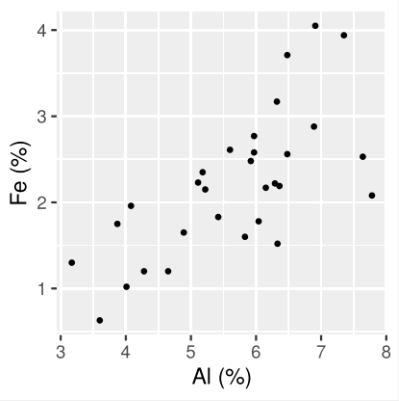

¿Como es la correlación? *Positiva, Nevativa, No* ¿Cómo cuantificarla?

Table of Contents

1. Causalidad vs. Correlación
2. Coeficientes de correlación
3. Modelo de regresión lineal simple
4. Modelo de regresión lineal múltiple
   - Análisis de Varianza
   - Coeficiente de determinación
   - Inferencia de los coeficientes
5. Conclusiones
6. Referencias

Coeficientes de correlación

- **El coeficiente de correlación es una medida estadística que indica la fuerza y la dirección de una relación lineal entre dos variables.**
- Su valor varía entre -1 y 1.
- Un coeficiente de correlación de 1 indica una correlación positiva perfecta, lo que significa que cuando una variable aumenta, la otra también lo hace de manera proporcional.
- Un coeficiente de correlación de -1 indica una correlación negativa perfecta, lo que significa que cuando una variable aumenta, la otra disminuye de manera proporcional.
- Un coeficiente de correlación de 0 indica que no hay ninguna relación lineal entre las dos variables.

Coeficientes de correlación

- **Pearson**: funciona bien para variables cuantitativas, método paramétrico(*), mide relación lineal, es sensible a valores extremos.

(*) Un método paramétrico es un enfoque estadístico que asume que los datos siguen una distribución específica y se basa en ciertos parámetros (como la media y la desviación estándar) para hacer inferencias sobre la población.

Coeficientes de correlación

- **Pearson:** funciona bien para variables cuantitativas, método paramétrico, mide relación lineal, es sensible a valores extremos.
- **Rho de Spearman:** se emplea principalmente para datos ordinales, de intervalo, cuantitativas que no satisfacen condición de normalidad, método no paramétrico, mide relación lineal y no lineal.

Coeficientes de correlación

- **Pearson:** funciona bien para variables cuantitativas, método paramétrico, mide ralación lineal, es sensible a valores extremos.
- **Rho de Spearman:** se emplea principalmente para datos ordinales, de intervalo, cuantitativas que no satisfacen condición de normalidad, método no paramétrico, mide relación lineal y no lineal.
- **Tau de Kendall:** método no paramétrico, se emplea cuando se dispone de pocos datos.

Coeficientes de correlación

Coeficiente de correlaci´on de Pearson: proporciona una medida de la relación lineal entre dos variables.

$$r = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sigma_x \sigma_y} \qquad (1)$$

Donde:
x_i y y_i representan las observaciones o puntos de muestras individuales indexados por i,
n es el tamaño de muestra,
$\bar{x}$ y $\bar{y}$ representan las medias,
y σ_x y σ_y son las deviaciones estándar de las variables x, y respectivamente.

Coeficientes de correlación

Covarianza

El numerador en la ecuación (1) se conoce como la covarianza:

$$C_{xy} = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}) \qquad (2)$$

se utiliza a menudo como una estadística resumida de un diagrama de dispersión (*Scatterplot).*

Coeficientes de correlación

Universidad Andrés Bello

Si la relación entre dos variables no es lineal, entonces se recomienda calcular un **coeficiente de correlación de rangos de Spearman**.

$$\rho_{rank} = \frac{C(R_X, R_Y)}{\sigma_{R_x}\sigma_{R_y}} \tag{3}$$

donde, $C(R_x, R_y)$ representa la covarianza del rango de las variables, y σ_{R_x}, σ_{R_y} las deviaciones de los rangos de las variables.
La (3) se reduce a la siguiente ecuación si todos los n rangos son distintos enteros,

$$r_S = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n(n^2 - 1)} \tag{4}$$

donde:
$d_i = \mathrm{rg}(X_i) - \mathrm{rg}(Y_i)$

Coeficientes de correlación

Tau de Kendall

$$\tau = \frac{2 * S}{n(n - 1)} \qquad (5)$$

donde: $S = \sum (n_c - n_d)$;
n_c es el número de pares concordantes,
n_d representa el número de pares discordantes.

Coeficientes de correlación

Dadas dos variables Y y X, la significancia de la correlación se analiza,
Prueba t

- H_0: $\rho = 0$ las variables son independientes
- H_1: $\rho \neq 0$ existe relación entre las variables

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}, \qquad df = n-2 \tag{6}$$

Si $P - value < 0.05$ entonces con un nivel de confianza del 95% se asegura relación estadísticamente significativa.
La cantidad de varianza de Y explicada por X se obtiene elevando al cuadrado el coeficiente de correlación R^2 y se conoce como coeficiente de determinación.

Coeficientes de correlación

Interpretación del valor de correlación.

Correlación	Interpretación
0.9 a 1.0 (-0.9 a -1.0)	muy fuerte
0.7 a 0.9 (-0.7 a -0.9)	fuerte
0.5 a 0.7 (-0.5 a -0.7)	moderada
0.3 a 0.5 (-0.3 a -0.5)	débil
0 a 0.3 (0 a -0.3)	despreciable

Coeficientes de correlación

Examples (1)

- Covarianza

$$C_{xy} = \frac{1}{30}\{(4.65 - 5.66)(1.2 - 2.2) + \ldots + (3.87 - 5.66)(1.75 - 2.2)\} \tag{7}$$
$$= \boxed{0.68}$$

Coeficientes de correlación

Examples (1)

- Covarianza

$$C_{xy} = \frac{1}{30}\{(4.65 - 5.66)(1.2 - 2.2) + \ldots + (3.87 - 5.66)(1.75 - 2.2)\} \\ = \boxed{0.68} \tag{7}$$

- Coeficiente de correlación de Pearson

$$\rho = \frac{C_{xy}}{\sigma_x \sigma_y} = \frac{0.68}{1.19 * 0.82} = \boxed{0.69} \tag{8}$$

Coeficientes de correlación

Examples (1)

- Covarianza

$$C_{xy} = \frac{1}{30}\{(4.65 - 5.66)(1.2 - 2.2) + \ldots + (3.87 - 5.66)(1.75 - 2.2)\} = \boxed{0.68} \tag{7}$$

- Coeficiente de correlación de Pearson

$$\rho = \frac{C_{xy}}{\sigma_x \sigma_y} = \frac{0.68}{1.19 * 0.82} = \boxed{0.69} \tag{8}$$

- Coeficiente de correlación de Spearman

$$r_s = \boxed{0.68} \tag{9}$$

Coeficientes de correlación

Examples (1)

Utilizando el coeficiente de correlación podríamos obtener una matriz de correlación para analizar la relación de estas dos variables con otros elementos medidos en los 30 sitios.

Pearson

	Al	Ca	Fe	K
Al	1.00	0.04	0.69	0.45
Ca	0.04	1.00	0.13	-0.22
Fe	0.69	0.13	1.00	0.05
K	0.45	-0.22	0.05	1.00

Spearman

	Al	Ca	Fe	K
Al	1.00	0.16	0.69	0.44
Ca	0.16	1.00	0.28	-0.15
Fe	0.69	0.28	1.00	0.1
K	0.44	-0.15	0.1	1.00

Coeficientes de correlación

Examples (1)

Gráfico de correlación

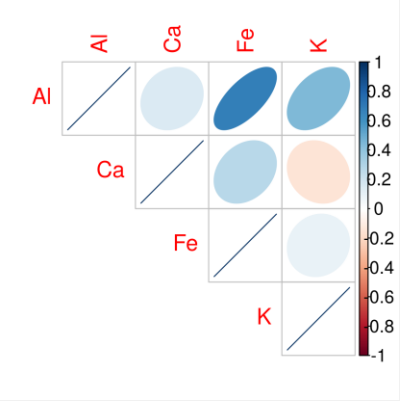

¿Podríamos estimar Fe conociendo Al?

Table of Contents

1. Causalidad vs. Correlación
2. Coeficientes de correlación
3. Modelo de regresión lineal simple
4. Modelo de regresión lineal múltiple
   - Análisis de Varianza
   - Coeficiente de determinación
   - Inferencia de los coeficientes
5. Conclusiones
6. Referencias

Modelo de regresión lineal simple

Examples (1)

Se desea encontrar un modelo que describa la relación entre las siguientes variables:

Años de experiencia	Salario
3	30
8	57
9	64
13	72
3	36
6	43
11	59
21	90
1	20
16	83

Modelo de regresión lineal simple

Examples (1)

Modelo de regresión lineal

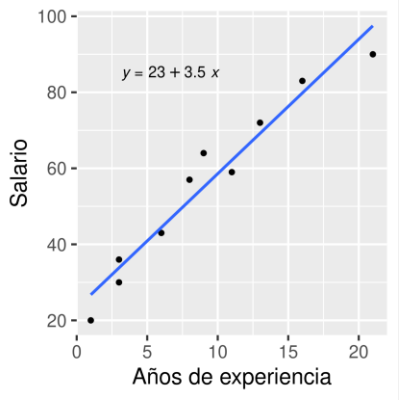

Modelo de regresión lineal simple

Modelo de Regresión Lineal Simple

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \qquad i = 1, 2, \ldots, n \tag{10}$$

donde se supone $\epsilon \sim \mathrm{N}(0, \sigma^2)$, y β_0, β_1 se conocen como coeficientes de regresión. La variable aleatoria y tiene distribución con media $E[y|x] = \beta_0 + \beta_1 x$ y varianza $Var[y|x] = \sigma^2$.

y	x
variable dependiente	variable independiente
variable explicada	variable explicativa
variable de respuesta	variable de control
variable predicha	variable predictora
regresando	regresor

Modelo de regresión lineal simple

Estimador de Mínimos Cuadrados Ordinarios (EMCO)
[Montgomery *et al.*, 2006]

Estimación de β_0 y β_1

$$\min S(\beta_0, \beta_1) = \sum_{i=1}^{n} (y_i - (\beta_0 + \beta_1 x_i))^2 \tag{11}$$

Modelo de regresión lineal simple

Estimador de Mínimos Cuadrados Ordinarios (EMCO)
[Montgomery *et al.*, 2006]

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}, \qquad \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} \tag{12}$$

donde,

$$S_{xx} = \sum_{i=1}^{n} (x_i - \bar{x})^2, \qquad S_{xy} = \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}) \tag{13}$$

Modelo de regresión lineal simple

Modelo de regresión lineal en forma matricial

$$\mathrm{Y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\epsilon} \tag{14}$$

con

$$\mathrm{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, \qquad \mathrm{X} = \begin{bmatrix} 1 & X_{11} \\ 1 & X_{12} \\ \vdots & \vdots \\ 1 & X_{1n} \end{bmatrix}, \qquad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}, \qquad \boldsymbol{\epsilon} = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

entonces los coeficientes β_0 y β_1 se pueden obtener como

$$\hat{\boldsymbol{\beta}} = (\mathrm{X}^T\mathrm{X})^{-1}\mathrm{X}^T\mathrm{Y} \tag{15}$$

Modelo de regresión lineal simple

Example (1)

$$\begin{bmatrix} 30 \\ 57 \\ 64 \\ \vdots \\ 83 \end{bmatrix} = \begin{bmatrix} 1 & 3 \\ 1 & 8 \\ 1 & 9 \\ \vdots & \vdots \\ 1 & 16 \end{bmatrix} * \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \vdots \\ \epsilon_{10} \end{bmatrix}$$

entonces,

$$\begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix} = \begin{bmatrix} 0.331 & -0.025 \\ -0.025 & 0.003 \end{bmatrix} * \begin{bmatrix} 554 \\ 6311 \end{bmatrix} = \begin{bmatrix} 23.21 \\ 3.54 \end{bmatrix}$$

el valor ajustado de la variable dependiente,

$$\hat{Y}_i = 23.21 + 3.54 X_i$$

Propiedades de los estimadores

- Estimadores insesgados,

$$E[\hat{\beta}_0] = \beta_0, \qquad E[\hat{\beta}_1] = \beta_1$$

- La suma de los residuos en cualquier modelo que contenga β_0 es igual a 0,

$$\sum_{i=1}^{n} (y_i - \hat{y}_i) = \sum_{i=1}^{n} e_i = 0$$

- $\sum_{i=1}^{n} y_i = \sum_{i=1}^{n} \hat{y}_i$
- La línea de regresión siempre pasa por el centroide $(\bar{x}, \bar{y})$
- $\sum_{i=1}^{n} x_i e_i = 0$
- $\sum_{i=1}^{n} \hat{y}_i e_i = 0$

Supuestos del EMCO

Existen 6 supuestos básicos sobre el EMCO [Rodr´iguez & González, 2017]

1. Linealidad,
2. Rango Completo,
3. Esperanza condicional de los errores nula
4. Perturbaciones esféricas,
5. Variables explicativas no aleatorias
6. Normalidad de los errores,

Supuestos del EMCO

1. **Linealidad:** El modelo es lineal si la función $f(\cdot)$ es lineal en los parámetros y en el término de error. Ejemplos:
   - Modelo lineal $Y = \beta_0 + \beta_1 X + \epsilon$
   - Modelo no lineal $Y = \beta_0 + \beta_1^2 X + \epsilon$
   - Modelo no lineal $Y = \beta_0 + \ln \beta_1 X + \epsilon$
   - Modelo no lineal $Y = \beta_0 + \beta_1 X * \epsilon$

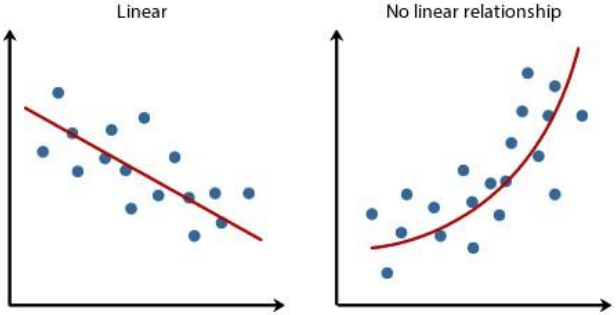

Supuestos del EMCO

2. **Rango Completo:** Las variables independientes deben ser independientes entre sí En términos matriciales, se entiende que las columnas son linealmente independientes. Ejemplo:

$$A = \begin{pmatrix} 1 & 2 & -1 \\ 2 & 4 & 0 \\ 3 & 6 & 5 \end{pmatrix}$$

Supuestos del EMCO

3. **Esperanza condicional de los errores nula:** Es una propiedad del EMCO, no es preciso verificar su cumplimiento (no hay sesgo).

$$E[\epsilon_i|X] = 0 \tag{16}$$

Implica:

$$\begin{cases} E[\epsilon_i] = 0 \\ Cov[X, \epsilon_i] = 0 \end{cases} \tag{17}$$

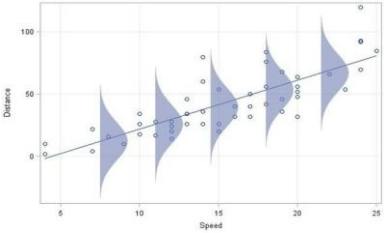

Supuestos del EMCO

Universidad Andrés Bello

4. **Perturbaciones esféricas:**
   - Homocedasticidad, varianza de los errores condicional a X es constante,

$$Var[\epsilon_i|X] = \sigma^2 \tag{18}$$

   - covarianza condicional de cualquier par de errores dados los valores de X es cero,

$$Cov[\epsilon_i, \epsilon_j|X] = 0 \tag{19}$$

   Si la base de datos es de serie de tiempos, este supuesto se conoce como la condición de <u>no autocorrelación</u>.

Al considerar ambos supuestos, implica la matriz de varianzas y covarianza,

$$Var(\epsilon) = \begin{pmatrix} \sigma^2 & 0 & 0 \\ 0 & \sigma^2 & 0 \\ 0 & 0 & \sigma^2 \end{pmatrix} = \sigma^2 \mathbb{I}_n \; ?\mathrm{I}_n \tag{20}$$

Supuestos del EMCO

4. **Perturbaciones esféricas:**

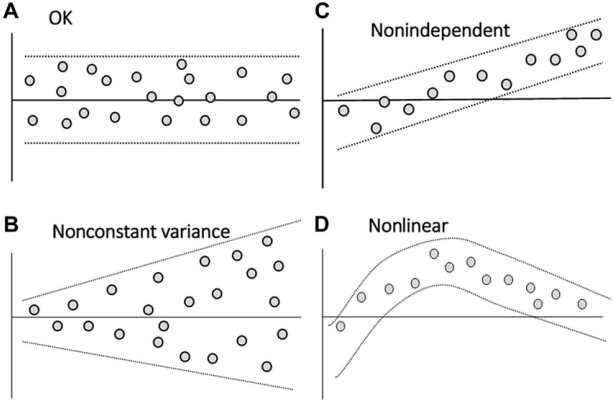

Supuestos del EMCO

5. **Variables explicativas no aleatorias:** Las variables independientes no son aleatorias, para un cierto momento t se conoce su valor con 100% de probabilidad, por lo que no dependen de alguna transformación generada de un proceso aleatorio.

Supuestos del EMCO

6. **Normalidad de los errores:** Se supone que los errores siguen distribución normal con media 0 y varianza σ^2.

$$\begin{aligned} \epsilon|X &\sim \mathrm{N}(0, \sigma^2 \mathrm{I}) \\ \epsilon_i &\sim \mathrm{N}(0, \sigma^2) \end{aligned} \tag{21}$$

Bajo este supuesto se cumple el teorema de *Rao-Blackwell*, indica que si el vector de errores se distribuye normal entonces el EMC tiene varianza mínima entre la clase de los estimadores insesgados.

El cumplimiento de los supuestos 1-5 hace que el estimador sea **BLUE**, se cumple el teorema de *Gauss-Markov*.

Table of Contents

1. Causalidad vs. Correlación
2. Coeficientes de correlación
3. Modelo de regresión lineal simple
4. Modelo de regresión lineal múltiple
   - Análisis de Varianza
   - Coeficiente de determinación
   - Inferencia de los coeficientes
5. Conclusiones
6. Referencias

Modelo de regresión lineal múltiple

Examples (2)

Con el fin de determinar la relación entre la calificación del desempeño laboral (y) y las calificaciones en cuatro exámenes (x_1), (x_2), (x_3) y (x_4), el departamento de personal de cierta empresa industrial realizó un estudio en el que participaron 12 sujetos.

y	x_1	x_2	x_3	x_4
11.2	56.5	71	38.5	43
14.5	59.5	72.5	38.2	44.8
17.2	69.2	76	42.5	49
17.8	74.5	79.5	43.4	56.3
19.3	81.2	84	47.5	60.2
24.5	88	86.2	47.4	62
21.2	78.2	80.5	44.5	58.1
16.9	69	72	41.8	48.1
14.8	58.1	68	42.1	46
20	80.5	85	48.1	60.3
13.2	58.3	71	37.5	47.1
22.5	84	87.2	51	65.2

Modelo de regresión lineal múltiple

Modelo de regresión lineal múltiple

Dado el modelo con p variables independientes:

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p + \epsilon \tag{22}$$

con $\epsilon \sim \mathrm{N}(0, \sigma^2)$ En forma matricial sería:

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{21} & \cdots & x_{p1} \\ 1 & x_{12} & x_{22} & \cdots & x_{p2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1n} & x_{2n} & \cdots & x_{pn} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix} \tag{23}$$

Donde el vector de parámetros β se obtiene,

$$\hat{\boldsymbol{\beta}} = (\mathrm{X}^T \mathrm{X})^{-1} \mathrm{X}^T \mathrm{Y} \tag{24}$$

Modelo de regresión lineal múltiple

Example (2)

$$Y = X\beta$$

$$\begin{pmatrix} 11.2 \\ 14.5 \\ 17.2 \\ \vdots \\ 22.5 \end{pmatrix} = \begin{pmatrix} 1 & 56.5 & 71 & 38.5 & 43 \\ 1 & 59.5 & 72.5 & 38.2 & 44.8 \\ 1 & 69.2 & 76 & 42.5 & 49 \\ \vdots & \vdots & \vdots & \vdots & \\ 1 & 84 & 87.2 & 51 & 65.2 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix}$$

Se puede estimar la variable de respuesta con el modelo,

$$\hat{Y}_i = 3.32 + 0.42X_1 - 0.3X_2 + 0.02X_3 + 0.12X_4$$

Análisis de Varianza

Sea el modelo de regresión lineal múltiple con p variables independientes, para probar la significancia del modelo se contrastan las hipótesis:

Hipótesis:

$$\begin{cases} H_0: & \beta_0 = \beta_1 = \cdots = \beta_p = 0 \\ H_1: & \text{algún } \beta_j \neq 0 \end{cases} \tag{25}$$

	Suma de cuadrados	Grados de libertad	Cuadrado medio	F_c
Regresión	SS_R	p	$MS_R = \frac{SS_R}{p}$	$F_c = \frac{MS_R}{MS_E}$
Error	SS_E	$n-p-1$	$MS_E = \frac{SS_E}{n-p-1}$	
Total	SS_T	$n-1$		

Decisión:

Rechazar H_0 si $P-valor < \alpha$, para $P-valor = 1 - P(|F_c| > F_{(a,p,n-p-1)})$

Análisis de Varianza

$$SS_R = \sum_{i=1}^{n} (\hat{Y}_i - \bar{Y})^2, \qquad SS_E = \sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2 \tag{26}$$

Estimador insesgado de σ^2

Un estimador insesgado de σ^2 es,

$$\hat{\sigma}^2 = MS_E = \frac{SS_E}{n - p - 1} \tag{27}$$

se conoce como cuadrado medio residual y la raíz cuadrada de $\hat{\sigma}^2$ se conoce como error estándar de la regresión.

Análisis de Varianza

Example (2)

Probar si el modelo es estadísticamente significativo

	Suma de cuadrados	Grados de libertad	Cuadrado medio	F_c	$P - valor$
Regresión	159.00	4	39.75	20.73	0.0006
Error	13.42	7	1.92		
Total	172.42	11			

¿Se puede rechazar la hipótesis nula?, (P- valor < 0.05) ? => rechaza Ho

¿el modelo es significativo?, F alto? P-valor pequeño? => significativo

Coeficiente de determinación R^2

Coeficiente de determinación R^2

Se interpreta como el porcentaje de variabilidad explicada por el modelo respecto la variabilidad total de la respuesta.

$$R^2 = \frac{SS_R}{SS_T} = 1 - \frac{SS_E}{SS_T}, \qquad R^2 \in [0, 1] \tag{28}$$

Coeficiente de determinación ajustado R_a^2

$$R_a^2 = 1 - \frac{MS_E}{MS_T} = 1 - \left[(1 - R^2)\frac{n-1}{n-p-1}\right], \qquad R_a^2 \in [0, 1] \tag{29}$$

Example (2)

$R^2 = \frac{159}{172.42} = 92.22\%$ y $R_a^2 = 1 - \frac{1.92}{15.67} = 87.75\%$

Inferencia de los coeficientes

Inferencia sobre β_j

Hipótesis

$$\begin{cases} H_0: & \beta_j = 0 \\ H_1: & \beta_j \neq 0 \end{cases} \tag{30}$$

Estadístico

$$t_c = \frac{\hat{\beta}_j}{se(\hat{\beta}_j)} \tag{31}$$

Donde el error estándar $se(\hat{\beta}_j)$ se calcula desde la matriz de varianzas y covarianzas:

$$Var(\beta_j) = MS_E * (X^T X)^{-1}, \qquad se(\hat{\beta}_1) = \sqrt{a_{22}} \tag{32}$$

Decisión:

se rechaza H_0 si $P - valor \leq \alpha$ con $P - valor = 2[1 - P(|t_c| > t)]$

Inferencia de los coeficientes

Example (2)

Hipótesis

$H_0: \quad \beta_j = 0$

$H_1: \quad \beta_j \neq 0$

	Estimación	Error Estándar	Estadístico t	P-valor
Intercepto	3.32	10.61	0.31	0.38
x_1	0.42	0.15	2.80	0.01
x_2	-0.3	0.26	-1.13	0.85
x_3	0.02	0.28	0.06	0.48
x_4	0.12	0.27	0.45	0.33

Intervalos de Confianza

Intervalo de Confianza β_j

$$\hat{\beta}_j - t_{(\alpha/2,n-p-1)} se(\hat{\beta}_j) \leq \beta_j \leq \hat{\beta}_j + t_{(\alpha/2,n-p-1)} se(\hat{\beta}_j) \tag{33}$$

Intervalo de Confianza $\hat{Y}_i$

$$\hat{Y}_i \pm t_{(\alpha/2,n-p-1)} \sqrt{MS_E \left(X_i (X^T X)^{-1} X_i^T \right)} \tag{34}$$

donde $X_i = \begin{bmatrix} 1 & x_{1i} & x_{2i} & \cdots & x_{pi} \end{bmatrix}$

Intervalo de Confianza Y_0 (predicción para observación futura)

$$\hat{Y}_0 \pm t_{(\alpha/2,n-p-1)} \sqrt{MS_E \left(1 + X_0 (X^T X)^{-1} X_0^T \right)} \tag{35}$$

Table of Contents

1. Causalidad vs. Correlación
2. Coeficientes de correlación
3. Modelo de regresión lineal simple
4. Modelo de regresión lineal múltiple
   - Análisis de Varianza
   - Coeficiente de determinación
   - Inferencia de los coeficientes
5. Conclusiones
6. Referencias

Conclusiones

- ¿Cómo cuantificar la relación entre variables?
- Definir el modelo de regresión lineal simple y múltiple.
- ¿Cómo estimar los parámetros del modelo?
- ¿Cuáles son las propiedades de los estimadores?
- ¿Cuáles son los supuestos del modelo de regresión lineal?
- ¿Cómo probar si el modelo es estad´ısticamente significativo?
- ¿Cómo probar si los coeficientes del modelo son estad´ısticamente significativo?
- Cálculo de los intervalos de confianza.

Table of Contents

1. Causalidad vs. Correlación
2. Coeficientes de correlación
3. Modelo de regresión lineal simple
4. Modelo de regresión lineal múltiple
   - Análisis de Varianza
   - Coeficiente de determinación
   - Inferencia de los coeficientes
5. Conclusiones
6. Referencias

Referencias

- Aggarwal, C. (2015) **"Data Mining: The Textbook"**, Springer International Publishing Switzerland.
- Boehmke, B. & Greenwell, B. (2020) **"Hands-On Machine Learning with R"**, Taylor & Francis Group, LLC.
- Bhatia, A. & Chiu, D. (2017) **"Machine learning with R cookbook: analyze data and build predictive models"**, Second edition, Packt Publishing Ltd., UK.
- EMC Education Services (2015). **"Data Science and Big Data analytics: Discovering, Analyzing, Visualizing and Presenting Data"**, 1st Edition, John Wiley & Sons.
- Hernández, J., Ram´ırez, M. J., Ferri, C. (2004) **"Introducci´on a la miner´ıa de datos"**, Pearson Educación, Madrid. ISBN 84-205-4091-9

Referencias

- Johnson, R. A. (2012) **"Probabilidad y estad´ıstica para ingenieros"**. Octava Ed. México: Pearson, 557 p.
- Montgomery, D. C., Peck, E. A. & Vining, G. G. (2006) **"Introducci´on al an´alisis de regresi´on lineal"**. Tercera Reimpresión, México.
- Rodr´ıguez, D. E. & González, G. J. (2017) **"Principios de econometr´ıa"**, Fondo Editorial ITM.
- Maurage, P., Heeren, A. & Pesenti, M. (2013) **"Does Chocolate Consumption Really Boost Nobel Award Chances? The Peril of Over-Interpreting Correlations in Health Studies"**, *The Journal of Nutrition*, doi:10.3945/jn.113.174813
- Smith, D. B., Ellefsen, K. J. & Kilburn, J. E. (2010) **"Geochemical Data for Colorado Soils: Results from the 2006 State-Scale Geochemical Survey"**, U.S. Geological Survey, Data Series 520.